

Dataset TTS Multiaccento Andaluz

Herramienta para construir una base de datos de audio normalizada destinada al fine-tuning de XTTS v2 (y modelos CoquiTTS compatibles), cubriendo los ocho acentos provinciales de Andalucía. Integra el Nomenclátor Geográfico de Andalucía (NGA) para mejorar la transcripción automática de topónimos locales.

Características principales

- **Asistente interactivo:** se ejecuta con un solo comando y guía al usuario paso a paso; no requiere argumentos en la línea de comandos.
- **Validación de municipios contra el NGA:** el código INE se obtiene directamente del CSV oficial; no es posible introducir un municipio que no exista en el NGA.
- **Topónimos NGA:** carga los topónimos normalizados/oficiales del municipio del hablante y los inyecta como `initial_prompt` en Whisper para reducir errores en nombres geográficos andaluces (cortijos, arroyos, haciendas, etc.).
- **Cobertura multiaccento:** organiza el dataset por provincia y municipio, generando un `metadata_global.csv` unificado apto para entrenar un único modelo con todos los acentos andaluces.
- **Soporte universal de formatos:** acepta cualquier archivo de audio o vídeo y extrae el audio automáticamente con ffmpeg.
- **Formato WAV para XTTS v2:** salida a 22 050 Hz, mono, 16-bit PCM.
- **VAD automático:** segmentación por silencios con fallback temporal; clips entre 2 y 15 segundos.
- **Transcripción automática:** Whisper con prompt de topónimos locales; reanudable (no reprocesa clips ya transcritos).
- **Split train/eval automático:** 85 % train / 15 % eval con semilla fija (`seed=42`), tanto local por municipio como global.

Requisitos

Sistema

```
# Linux / macOS
sudo apt install ffmpeg # Debian/Ubuntu
brew install ffmpeg     # macOS

# Windows
winget install Gyan.FFMpeg
```

Python (3.9 o superior recomendado)

```
pip install openai-whisper pydub
```

Instalación

1. Descarga o clona el script `procesar_audios_andalucia.py`.
2. Coloca el CSV del NGA en la misma carpeta que el script (o edita la constante `NGA_CSV` al inicio del archivo).

Descarga oficial: <https://www.ieca.junta-andalucia.es/nomenclator/>

Rutas configurables

Las tres rutas del proyecto se definen como constantes al inicio del script. Edítalas antes de ejecutar si necesitas cambiar la ubicación por defecto:

```
# — RUTAS (ajusta aquí antes de ejecutar) —————
NGA_CSV      = Path(__file__).parent / "NGA_TOPONIMOS_20260309.csv"
OUTPUT_ROOT  = Path(__file__).parent / "dataset"
GLOBAL_CSV   = OUTPUT_ROOT / "metadata_global.csv"
```

Uso

```
python procesar_audios_andalucia.py
```

El script no necesita argumentos. Al ejecutarse, lanza un asistente interactivo que pregunta:

Paso	Pregunta	Validación
1	Carpeta de entrada	Debe existir y contener archivos A/V
2	Provincia	Nombre o código de 2 dígitos; solo las 8 provincias andaluzas
3	Municipio	Búsqueda parcial contra el NGA; el código INE se asigna automáticamente
4	ID de hablante	Exactamente 2 dígitos (ej.: 01, 02)
5	Modelo Whisper	Nombre o número de lista; por defecto <code>large-v3</code>

Tras mostrar un resumen, el usuario confirma o reinicia el asistente.

Ejemplo de sesión

```
=====
Procesador TTS Multiaccento Andaluz – dataset XTTS v2
=====
```

Carpeta con los audios/vídeos de entrada: audios/utrer

✓ 12 archivo(s) encontrado(s).

Provincias disponibles:

04 · Almeria 11 · Cadiz 14 · Cordoba ...

Provincia (nombre o código de 2 dígitos): Sevilla

✓ Provincia: Sevilla (código 41)

Municipio (nombre, puede ser parcial): utr

✓ Municipio: Utrera (INE 41095)

ID de hablante (2 dígitos, ej: 01): 01

✓ Hablante: 01

Modelo Whisper [large-v3]:

✓ Modelo: large-v3

RESUMEN

Entrada : audios/utrer
Dataset raíz : dataset/
Provincia : Sevilla (código 41)
Municipio : Utrera (INE 41095)
Hablante ID : 01
Modelo Whisper : large-v3

¿Continuar con estos parámetros? (S/n): s

Provincias válidas

Código	Provincia
04	Almería
11	Cádiz
14	Córdoba
18	Granada
21	Huelva
23	Jaén
29	Málaga
41	Sevilla

Estructura de salida

```
dataset/
├── Sevilla/
│   └── Utrera_41095/
│       ├── wavs/
│       │   ├── 41095_01_01.wav
│       │   ├── 41095_01_02_seg01.wav
│       │   └── ...
│       ├── metadata.csv
│       ├── metadata_train.csv
│       ├── metadata_eval.csv
│       └── toponimos_41095.txt
├── Granada/
│   └── Granada_18087/
│       ├── wavs/
│       │   ├── metadata.csv
│       │   ├── metadata_train.csv
│       │   ├── metadata_eval.csv
│       │   └── toponimos_18087.txt
├── metadata_global.csv
├── metadata_global_train.csv
└── metadata_global_eval.csv
```

Nomenclatura de WAVs

<cod_municipio>_<hablante>_<num_archivo>[_seg<NN>].wav

Ejemplo: 41095_01_03_seg02.wav

```
├── segmento 2 (VAD)
├── archivo de entrada nº 3
├── hablante 01
└── municipio Utrera (41095)
```

Formato de los CSV

CSV local (metadata.csv):

```
audio|transcripcion|idioma
wavs/41095_01_01.wav|En Utrera el Corpus es una fiesta muy antigua.|es
```

CSV global (metadata_global.csv) — añade dos columnas:

```
audio|transcripcion|idioma|municipio|provincia
wavs/41095_01_01.wav|En Utrera el Corpus es una fiesta muy antigua.|es|Utrera|Sevilla
```

Cada nueva ejecución añade sus filas al CSV global sin sobrescribir lo anterior y regenera el split global.

Formatos de entrada soportados

Tipo	Extensiones
Audio	.ogg .opus .mp3 .m4a .aac .wav .flac .wma .amr .3gp
Vídeo	.mp4 .mkv .avi .mov .wmv .webm .ts .mts .m2ts .flv .ogv

El audio se extrae de los vídeos automáticamente con ffmpeg.

Topónimos NGA

Para cada municipio procesado, el script:

1. Filtra del CSV del NGA los topónimos con `VSTATUS = Normalizado u Oficial` pertenecientes al código de municipio indicado.
2. Construye un `initial_prompt` para Whisper priorizando los nombres más largos (nombres compuestos primero), limitado a ~200 tokens.
3. Guarda la lista completa en `toponimos_<cod>.txt` para revisión manual.

Recomendación: revisa el fichero `toponimos_XXXXX.txt` y corrige manualmente en el CSV las transcripciones que contengan topónimos mal reconocidos antes de iniciar el entrenamiento.

Parámetros de segmentación

Parámetro	Valor	Descripción
MIN_DURATION	2 s	Duración mínima de un clip
MAX_DURATION	15 s	Duración máxima de un clip
SILENCE_THRESH	-40 dBFS	Umbral de detección de silencio
MIN_SILENCE_MS	400 ms	Duración mínima del silencio para cortar
KEEP_SILENCE_MS	100 ms	Silencio que se conserva en cada extremo del clip

Estos valores pueden ajustarse editando las constantes al inicio del script.

Modelos Whisper disponibles

Modelo	Uso recomendado
tiny	Pruebas rápidas, hardware muy limitado
base	Pruebas rápidas
small	Balance velocidad/calidad
medium	Hardware limitado, buena calidad

Modelo	Uso recomendado
large	Alta calidad
large-v2	Alta calidad mejorada
large-v3	Máxima precisión ← por defecto

Recomendaciones para el fine-tuning

- **Calidad mínima recomendada:** 30 minutos de audio por hablante; 1 hora o más por acento para resultados óptimos.
- **Diversidad textual:** incluye frases con topónimos locales, vocabulario dialectal (ceceo, yeísmo, aspiraciones) y diferentes registros.
- **Revisión manual:** antes de entrenar, abre el CSV en un editor de texto o en Excel y corrige las transcripciones con errores evidentes, especialmente topónimos y palabras dialectales.
- **Dataset global:** usa `metadata_global_train.csv` y `metadata_global_eval.csv` para entrenar un modelo multiaccento unificado.

Licencia y créditos

- **NGA (Nomenclátor Geográfico de Andalucía):** Instituto de Estadística y Cartografía de Andalucía (IECA), Junta de Andalucía. Datos de uso libre bajo licencia [CC BY 4.0](#).
- **Whisper:** OpenAI — <https://github.com/openai/whisper>
- **XTTS v2 / Coqui TTS:** CoquiAI — <https://github.com/coqui-ai/TTS>